

Primeira prova de Estatística - GBC041

Instruções: todos os códigos das questões devem estar em um único arquivo `.R` ou em um único arquivo `.qmd`, que deverá poder ser executado do início ao fim sem erros. Os gráficos solicitados também devem ser anexados à tarefa. No início do arquivo, utilize o comando `set.seed()` com a soma dos números de matrícula dos dois integrantes da dupla, considerando apenas os dígitos, isto é, removendo as letras. Por exemplo, para as matrículas fictícias 12345ABC678 e 98765XYZ432, utilize `set.seed(12345678 + 98765432)`. Respostas interpretativas devem ser escritas como comentários no código.

Questão 1. Dois dados honestos de seis faces serão lançados 60 vezes. Em cada lançamento, registra-se a soma das faces obtidas.

- (a) Simule esse experimento e guarde as 60 somas em um vetor chamado `somas`.
- (b) Quantas vezes foi obtida soma igual a 7? Em quais lançamentos (posições) foi obtida soma maior do que 10?
- (c) Calcule a média, a mediana, o primeiro e o terceiro quartis e a moda das somas obtidas. Algumas funções úteis são `mean()`, `median()`, `quantile()` e `summary()`; para a moda, utilize `table()` em conjunto com `which.max()` ou `max()`. Em seguida, interprete cada uma dessas medidas no contexto do experimento: o que elas dizem sobre as somas obtidas nos 60 lançamentos? Os valores encontrados são compatíveis com o que você esperaria ao lançar dois dados honestos? Justifique.

Questão 2. Mario e Luigi disputam o seguinte jogo. Eles lançam, alternadamente, um dado honesto de seis faces, sempre começando por Mario. Vence o jogo quem obtiver o número 6 primeiro.

- (a) Crie uma função que simule uma partida desse jogo. A função deverá retornar `"mario"` se Mario vencer e `"luigi"` se Luigi vencer.
- (b) Repita o experimento 100 mil vezes e calcule a proporção de partidas vencidas por Mario. O jogo é justo? Comente o resultado obtido.
- (c) Modifique a função do item (a) para que ela também retorne o número total de lançamentos realizados na partida. Repita o experimento 100 mil vezes, calcule a média e a mediana do número de lançamentos e interprete esses valores. Por que a média e a mediana são diferentes?

Exemplos: se os resultados dos lançamentos forem (6), Mario vence após 1 lançamento; se forem (3, 6), Luigi vence após 2 lançamentos; se forem (2, 5, 1, 4, 6), Mario vence após 5 lançamentos.

Questão 3. Ash quer completar sua coleção de seis insígnias. Cada vez que vence uma batalha, ele recebe uma insígnia escolhida ao acaso entre as seis possíveis, todas com a mesma probabilidade, podendo receber insígnias repetidas. Ash continua batalhando até possuir as seis insígnias diferentes.

- (a) Crie uma função que simule a jornada de Ash e retorne o número de batalhas necessárias para completar a coleção. Por exemplo, se as insígnias recebidas forem 2, 5, 2, 1, 6, 6, 3, 2, 4, a função deverá retornar 9.
- (b) Repita o experimento 100 mil vezes e guarde os resultados em um vetor chamado `batalhas`. Calcule a média, a mediana, os quartis, o valor mínimo e o valor máximo de `batalhas`. Interprete a média e o terceiro quartil.
- (c) Construa um histograma e um boxplot de `batalhas`. O que esses gráficos revelam sobre a distribuição do número de batalhas?
- (d) Estime a probabilidade de que Ash precise de mais de 20 batalhas para completar a coleção.

Questão 4. O conjunto de dados `airquality`, disponível no R, contém medições diárias da qualidade do ar em Nova York entre maio e setembro de 1973. As variáveis são a concentração de ozônio em partes por bilhão (`Ozone`), a radiação solar (`Solar.R`), a velocidade média do vento em milhas por hora (`Wind`), a temperatura máxima diária em graus Fahrenheit (`Temp`), o mês (`Month`) e o dia do mês (`Day`).

- (a) O conjunto já vem instalado com o R, no pacote `datasets`, que é carregado automaticamente; não é necessário baixar nenhum arquivo nem instalar pacotes. Para acessá-lo, basta digitar `airquality`

no console, ou salvá-lo em um objeto com `dados <- airquality`. Entenda a estrutura do conjunto. Quantas observações faltantes (NA) há em cada variável?

- (b) Utilizando a função `mutate()` do pacote `dplyr`, crie uma nova variável `TempC`, com a temperatura em graus Celsius, a partir da relação $C = \frac{5}{9}(F - 32)$. Em seguida, transforme a variável `Month` em um fator cujos níveis sejam os nomes dos meses. *Sugestão:* `factor(Month, levels = 5:9, labels = c("Maio", "Junho", "Julho", "Agosto", "Setembro"))`.
- (c) Utilizando a função `filter()`, crie dois novos data.frames: um apenas com os dias de maio e outro apenas com os dias de julho. Para cada um deles, calcule a média, a mediana e os quartis da variável `Ozone`, desconsiderando as observações faltantes (argumento `na.rm = TRUE`). Em qual dos dois meses a concentração de ozônio foi mais alta? Em cada mês, a média e a mediana são próximas? O que isso indica sobre a distribuição do ozônio?
- (d) Utilizando o pacote `ggplot2`, construa um boxplot da variável `Ozone` para cada mês (com `Month` no eixo horizontal) e um gráfico de dispersão relacionando `TempC` e `Ozone`. Comente os gráficos obtidos. *Sugestão:* utilize as camadas `geom_boxplot()` e `geom_point()`.